

Домашнее задание

Практическое использование алгоритма BLAST

Дедлайн 16 апреля 23.59

Введение

Для выполнения этого задания вам потребуется веб-интерфейс NCBI BLAST. В ответах приводите скриншоты или текстовые выписки из результатов, а также подробное объяснение ваших действий и выводов.

Задание 1. Идентификация белка и интерпретация E-value (1 балл)

Вам дана аминокислотная последовательность неизвестного белка. Ссылка на последовательность: NP_000537.3

1.1 Запустите BLASTP по базе данных nr (Non-redundant protein sequences).

1.2 Ответьте на вопросы:

- Как называется этот белок и какому организму принадлежит лучшая находка (top hit)?
- Чему равно значение E-value для первой находки?
- Объясните своими словами, что означает это конкретное значение E-value в контексте размера базы данных nr. Почему сырой балл (Raw Score) нельзя использовать напрямую для оценки значимости?

Ответы:

Descriptions

Graphic Summary

Alignments

Taxonomy

Sequences producing significant alignments

DownloadSelect columnsShow100?

☒ select all100 sequences selected

GenPeptGraphicsDistance tree of resultsMultiple alignmentMSA Viewer

	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	cellular tumor antigen p53 isoform X1 [Gorilla gorilla gorilla]	Gorilla gorilla gorilla	814	814	100%	0.0	99.75%	408	XP_063556659.1
☒	Chain K, Cellular tumor antigen p53 [Homo sapiens]	Homo sapiens	814	814	100%	0.0	100.00%	395	7XZZ_K
☒	Chain C, Cellular tumor antigen p53 [Homo sapiens]	Homo sapiens	814	814	100%	0.0	100.00%	417	8R1F_C
☒	cellular tumor antigen p53 isoform a [Homo sapiens]	Homo sapiens	813	813	100%	0.0	100.00%	393	NP_000537.3

1. cellular tumor antigen p53 isoform X1 [Gorilla gorilla gorilla]

2. 0 (видимо очень маленькое значение)

3. E-value это ожидаемое число случайных совпадений в конкретной базе данных. Если бы в данной базе данных нашлось бы случайное совпадение, то у него был бы такой же Raw Score, что делает данную метрику малоинформативной в контексте значимости.

Задание 2. Поиск транслированных последовательностей (1 балл)

У вас есть нуклеотидная последовательность (мРНК бета-глобина человека). Ссылка на последовательность: NM_000518.5

2.1 Если мы хотим найти гомологичные белки для этой нуклеотидной последовательности, какой инструмент BLAST следует использовать (blastn, blastp, blastx, tblastn или tblastx) и почему?

2.2 Запустите выбранный инструмент по базе белков (nr) или Swissprot.

2.3 Какая рамка считывания (Reading frame) оказалась верной для выравнивания с лучшим найденным белком? (Укажите, например, +1, -2 и т.д., эту информацию можно найти в деталях выравнивания).

2.4 Почему этот подход надежнее, чем самостоятельная трансляция мРНК в белок (например, через сторонние программы-трансляторы) с последующим запуском обычного BLASTP?

Ответы:

Descriptions	Graphic Summary	Alignments	Taxonomy					
Sequences producing significant alignments								
Download Select columns Show 100								
☐ select all 0 sequences selected								
GenPept Graphics								
Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☐ hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	70%	1e-101	100.00%	148	AAX37051.1
☐ hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	70%	1e-101	100.00%	148	AAX29557.1
☐ hemoglobin subunit beta [Homo sapiens]	Homo sapiens	301	301	70%	2e-101	100.00%	147	NP_000509.1
☐ hemoglobin subunit beta [Gorilla gorilla gorilla]	Gorilla gorilla go...	300	300	70%	6e-101	99.32%	147	XP_018891709.1
☐ beta globin chain variant [Homo sapiens]	Homo sapiens	299	299	70%	6e-101	99.32%	147	AAN84548.1
☐ beta-globin [Homo sapiens]	Homo sapiens	299	299	70%	6e-101	99.32%	147	ACU56984.1
☐ beta globin [Homo sapiens]	Homo sapiens	299	299	70%	6e-101	99.32%	147	AAZ39780.1
☐ hemoglobin beta chain [Homo sapiens]	Homo sapiens	299	299	70%	8e-101	99.32%	147	AAD19696.1
☐ HBB, partial [synthetic construct]	synthetic construct	299	299	70%	8e-101	99.32%	147	AKI70610.1
☐ HBB, partial [synthetic construct]	synthetic construct	299	299	70%	1e-100	99.32%	147	AKI70611.1

1. blastx - он даёт возможность конвертировать заданную последовательность мРНК в 6 возможных рамок считывания и пройтись ими по всей базе.

Descriptions	Graphic Summary	Alignments	Taxonomy					
Sequences producing significant alignments								
Download Select columns Show 100								
select all 1 sequences selected								
GenPept Graphics Distance tree of results Multiple alignment MSA Viewer								
Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒ Biochemic_Full-Hemoglobin_AltName_Full-Hemoglobin_MBL_AltName_Full-Hemoglobin_MBL(Danio rerio)	Danio rerio	115	115	95%	9e-35	43.15%	147	Q01946.3

3. +3

4.ну мы тогда просто только одну рамку считывания чекнем и скорее всего будем не правы. оптимальный подход чекать сразу все - мы же буквально просто достаём чаще всего обрубков изначальной цепи мРНК, у которой рамка считывания неизвестна.

Задание 3. Влияние матриц аминокислотных замен (1 балл)

Рассмотрим белок миоглобин человека. Ссылка на последовательность: NP_005359.1

3.1 Запустите BLASTP для этой последовательности по базе данных SwissProt, используя стандартные параметры (матрица BLOSUM62). Найдите гомолог из организма Danio rerio (Zebrafish). Запишите его E-value, Bit Score и процент идентичности (Identity).

3.2 Теперь в разделе Algorithm parameters поменяйте матрицу на PAM30 и запустите поиск снова.

3.3 Найдите тот же самый белок Danio rerio в результатах. Как изменились E-value, Bit Score и длина покрытия (Query cover)?

3.4 Объясните наблюдаемые изменения. Для поиска каких (близких или эволюционно далеких) гомологов лучше подходит PAM30, а для каких BLOSUM62?

Descriptions	Graphic Summary	Alignments	Taxonomy					
Sequences producing significant alignments								
Download			Select columns					
Show			100					
☒ select all 1 sequences selected								
GenPept Graphics Distance tree of results Multiple alignment MSA Viewer								
Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒ RecName: Full=Myoglobin; AltName: Full=Nitrite reductase MB; AltName: Full=Pseudoperoxidase MB [Danio rerio]	Danio rerio	115	115	95%	9e-35	43.15%	147	Q6VN46.3

Score	Expect	Method	Identities	Positives	Gaps
115 bits(289)	9e-35	Compositional matrix adjust.	63/146(43%)	88/146(60%)	3/146(2%)
Query 9	QLVLNVWGKVEADIPGHGQEVLI	IRLFK	GH	PETLEKFDKFKHLKSEDEMKASEDLKKHGAT	68
Sbjct 5	DLVLKCGWAVEADYAANGGEVLN	RRLF	KEYPDTLKLFPKFSGI-SQGDLAGSPA	VAHGAT	63
Query 69	VLTALGGILKKKGHHEAEIKPLAQSHATKHKIPVKYLEFISECIIQVLQSKHPGDFGADA	128			
Sbjct 64	VLKKGELLLKAKGDHAALLKPLANTHANIHKVALNNFRLITEVLVKVMAEKAGLD--AAG	121			
Query 129	QGAMNKALELFRKDMASNYKELGFQG	154			
Sbjct 122	QGALRRVMDAVIDGIDGYKKEIGFAG	147			

Ответы:

1. 9e-35, 115, 43 процента

3.2e-29, 119, 42 процента Query cover 97 процентов

4. PAM30 больше штрафует за несоответствия и потому менее пригодна для сравнения из-за чего E-value повышается у истинного выравнивания (это плохо.) У BLOSUM62 наоборот.

Download	GenPept	Graphics	Next	Previous	Descriptions
RecName: Full=Myoglobin; AltName: Full=Nitrite reductase MB; AltName: Full=Pseudoperoxidase MB [Danio rerio]					
Sequence ID: Q6VN46.3 Length: 147 Number of Matches: 1					
Range 1: 2 to 147 GenPept Graphics					
Score	Expect	Method	Identities	Positives	Gaps
119 bits(274)	2e-29	Compositional matrix adjust.	62/149(42%)	73/149(48%)	3/149(2%)
Query 6	GEWQLVLNVWGKVEADIPGHGQEVLI	IRLFK	GH	PETLEKFDKFKHLKSEDEMKASEDLKKH	65
Sbjct 2	ADHDLVLKCGWAVEADYAANGGEVLN	RRLF	KEYPDTLKLFPKFSGI-SQGDLAGSPA	VAH	60
Query 66	GATVLTALGGILKKKGHHEAEIKPLAQSHATKHKIPVKYLEFISECIIQVLQSKHPGDFG	125			
Sbjct 61	GATVLTALGGILKKKGHHEAEIKPLAQSHATKHKIPVKYLEFISECIIQVLQSKHPGDFG	118			
Query 126	ADAQGAMNKALELFRKDMASNYKELGFQG	154			
Sbjct 119	AAGQALRRVMDAVIDGIDGYKKEIGFAG	147			

Задание 4. Таксономические фильтры и поиск ортологов (2 балла)

Ген BRCA1 хорошо изучен у человека в контексте рака молочной железы. Ссылка на последовательность белка: NP_009225.1

4.1 Ваша задача найти ортолог этого белка у плодовой мушки (*Drosophila melanogaster*).

4.2 Запустите BLASTP, в поле Organism введите Drosophila melanogaster (taxid: 7227).

4.3 Как называется лучший хит у мушки?

4.4 Насколько сильно этот белок похож на человеческий? Укажите Query Cover и Per. Ident.

4.5 Посмотрите на графическое представление выравнивания (вкладка Graphics). Сохранился ли белок целиком или консервативны только отдельные домены? Какие выводы об эволюции этого белка можно сделать?

	Cluster Composition	Cluster Ancestor	Cluster Representative Sequence	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
☒	2 member(s), 1 organism(s)	fruit fly	uncharacterized protein Dmel_CG44271 [Drosophila melanogaster]	57.8	57.8	2%	8e-10	54.35%	106	NP_001285689.1
☒	2 member(s), 1 organism(s)	fruit fly	degringolade_isoform B [Drosophila melanogaster]	52.0	52.0	3%	2e-06	35.09%	312	NP_731017.1
☒	43 member(s), 31 organism(s)	flies	Sex combs extra [Drosophila melanogaster]	52.0	52.0	3%	2e-06	37.31%	435	NP_477509.1
☒	1 member(s), 1 organism(s)	fruit fly	degringolade_isoform D [Drosophila melanogaster]	49.7	49.7	3%	3e-06	35.09%	205	NP_001287188.1

3. uncharacterized protein Dmel_CG44271 [Drosophila melanogaster]

4. 2 процента, 54.35 процентов

5. сохранились отдельные домены - они консервативные и почему-то по ним всё время шёл отбор.

